VPS Setup Checklist dan Template Konfigurasi Aman

Urutan kerja untuk menjalankan model open-weight di VPS sendiri tanpa server tumbang dan tanpa port terbuka ke internet.

1. Sebelum menyentuh instalasi

Periksa	Target	Siap?
Spesifikasi	Catat RAM, vCPU, disk, dan apakah ada GPU. Tentukan batas model.	
Akses	Ada akses SSH dengan kunci, bukan kata sandi.	
Pulih	Ada cara membangun ulang server ini dari nol tanpa panik.	
Anggaran	Ada batas biaya bulanan yang ditulis, bukan diperkirakan sambil jalan.	

2. Urutan instalasi

Langkah	Yang dilakukan	Selesai kalau
1	Perbarui paket sistem dan buat pengguna non-root untuk menjalankan aplikasi.	Aplikasi tidak jalan sebagai root.
2	Pasang runtime dan dependensi dengan versi yang dipin.	Versi tercatat, bukan versi terbaru apa saja.
3	Unduh bobot model dan simpan di direktori data terpisah.	Bobot tidak bercampur dengan kode.
4	Letakkan konfigurasi di berkas environment, bukan di argumen perintah.	Tidak ada rahasia yang menempel di riwayat perintah.
5	Batasi sumber daya: memori, CPU, dan proses bersamaan.	Ada plafon yang tertulis dan diuji.
6	Jalankan sebagai layanan dengan restart otomatis.	Layanan hidup lagi setelah reboot.
7	Letakkan reverse proxy di depan layanan.	Port aplikasi hanya menerima dari localhost.
8	Pasang sertifikat TLS dan paksa HTTPS.	HTTP biasa dialihkan, bukan melayani.
9	Verifikasi dari luar.	Endpoint menjawab sehat, port internal tertutup.

3. Checklist sizing hardware

Komponen	Acuan aman	Catatan
Memori	Model 7B kuantisasi 4-bit butuh sekitar 6 sampai 8 GB, sisakan 2 GB untuk sistem.	Kekurangan memori adalah penyebab paling umum VPS hang.
vCPU	Minimal 4 untuk satu sesi tunggal, 8 untuk beberapa sesi bersamaan.	Terlalu sedikit core membuat waktu jawab tidak stabil.
Disk	Sediakan ruang untuk bobot model, log, dan cache. Bobot mudah membengkak.	Pakai disk terpisah untuk data bila memungkinkan.
GPU	Opsional. Tanpa GPU, waktu jawab jauh lebih lambat tapi tetap bisa dipakai untuk uji.	Jangan janjikan kecepatan GPU kalau tidak ada GPU.
Swap	Aktifkan swap sebagai jaring pengaman, bukan sebagai pengganti memori.	Swap yang terus terpakai berarti memori kurang.

4. Konfigurasi yang paling sering salah

Kesalahan	Akibatnya	Perbaikannya
Binding ke 0.0.0.0 hanya demi mudah dites	Layanan terbuka ke internet	Binding ke 127.0.0.1, akses lewat proxy
Menempelkan kunci API di baris perintah	Rahasia masuk riwayat shell dan log	Pakai berkas environment dengan izin terbatas
Tanpa batas memori	Server tumbang saat beban naik	Pasang plafon memori dan uji sampai batasnya
Tanpa batas konkurensi	Antrean menumpuk, waktu jawab ambruk	Batasi permintaan bersamaan
Log tanpa rotasi	Disk penuh dalam hitungan pekan	Aktifkan rotasi dan batas ukuran log

5. Template Docker Compose

```
services:
  model:
    image:
    container_name: llm-server
    command: ["--host", "0.0.0.0", "--port", "8080", "--ctx-size", "4096"]
    volumes:
      - ./data/models:/models:ro
    environment:
      - MODEL_PATH=/models/.gguf
      - N_THREADS=
    mem_limit:
    cpus: ""
    ports:
      - "127.0.0.1:8080:8080"   # HANYA localhost. proxy yang menghadap internet.
    restart: unless-stopped
    logging:
      driver: json-file
      options:
        max-size: "10m"
        max-file: "3"
```

Poin penting: binding ke 127.0.0.1, bukan 0.0.0.0. Plafon memori dan CPU wajib, bukan opsional. Rotasi log wajib supaya disk tidak penuh.

6. Nginx reverse proxy dengan autentikasi header

```
map $http_authorization $api_auth_ok {
    default                     0;
    "Bearer " 1;
}
server {
    listen 443 ssl;
    server_name ;
    ssl_certificate     /etc/letsencrypt/live//fullchain.pem;
    ssl_certificate_key /etc/letsencrypt/live//privkey.pem;
    client_max_body_size 2m;
    location / {
        if ($api_auth_ok = 0) { return 401; }
        proxy_pass         http://127.0.0.1:8080;
        proxy_http_version 1.1;
        proxy_set_header   Host              $host;
        proxy_set_header   X-Real-IP         $remote_addr;
        proxy_set_header   X-Forwarded-For   $proxy_add_x_forwarded_for;
        proxy_set_header   X-Forwarded-Proto $scheme;
        proxy_read_timeout    300s;
        proxy_send_timeout    300s;
        proxy_buffering       off;
    }
}
server {
    listen 80;
    server_name ;
```

```
    return 301 https://$host$request_uri;
}
```

Token di header ini adalah lapisan pertama, bukan satu-satunya. Ganti token sebelum dipakai orang lain, simpan di berkas dengan izin terbatas, dan jangan pernah menaruhnya di repo.

7. Aturan firewall

```
URUTAN PEMASANGAN (jangan dibalik, bisa terkunci sendiri)
1. Pastikan SSH masih terbuka sebelum mengaktifkan firewall.
2. Izinkan SSH, lalu HTTP dan HTTPS untuk proxy.
3. Tolak semua port lain dari luar.
4. Kunci port model (8080) agar hanya bisa diakses dari localhost.
5. Uji dari mesin lain, bukan hanya dari server itu sendiri.
6. Simpan aturan aktif ke berkas agar bertahan setelah reboot.
7. Verifikasi lagi setelah reboot.
PRINSIP
- port model tidak pernah terbuka ke internet, hanya lewat proxy
- setiap port yang dibuka punya alasan tertulis dan satu nama penanggung jawab
- kalau belum butuh dibuka, jangan dibuka
```

8. Verifikasi setelah naik

Uji	Cara	Hasil yang diharapkan
Kesehatan layanan	Panggil endpoint sehat dari server itu sendiri.	Jawaban sehat dan cepat.
Isolasi port	Coba akses port aplikasi dari mesin lain.	Koneksi ditolak.
Paksa HTTPS	Akses lewat HTTP biasa.	Dialihkan ke HTTPS.
Pulih setelah reboot	Reboot lalu tunggu beberapa menit.	Layanan hidup tanpa campur tangan.
Beban wajar	Kirim beberapa permintaan berurutan.	Waktu jawab stabil, tidak ada proses yang dimatikan sistem.

9. Sebelum dipakai kerja nyata

Tentukan siapa yang boleh memakainya, data apa yang boleh masuk, dan bagaimana log ditinjau. Server yang rapi tapi tanpa aturan data hanya memindahkan masalah ke tempat yang lebih sulit dilihat.

Catatan: jalankan satu perubahan pada satu waktu, lalu verifikasi. Perubahan bertumpuk membuat penyebab kegagalan tidak bisa dilacak.